


Resumen

AIDOC es una plataforma de analisis documental conversacional (RAG). El usuario sube una biblioteca de documentos (subida manual o desde Google Drive / OneDrive) que se indexan en una base vectorial; luego puede chatear sobre ellos con respuestas citadas y generar cotizaciones guiadas por cotizaciones existentes, editables antes de exportarlas. Aplicacion standalone, single-tenant hoy y disenada para multi-tenant sin migracion.

Diagrama de componentes



Stack tecnologico

Capa	Tecnologia
Frontend	React 18 + Vite + TypeScript + TailwindCSS (SPA, SSE, dark mode)
Backend / API	Python 3.11 + FastAPI (async), SQLAlchemy 2 + Alembic
Base de datos	PostgreSQL (metadata: documentos, chats, cotizaciones, organizacion)
Vector store	Qdrant en HPE PCAI (embeddings filtrados por tenant_id; sin API key)
Almacenamiento	MinIO / S3 (archivos originales)
Cola / worker	Redis + ARQ (indexado asincrono en segundo plano)

OCR	Tesseract (pytesseract + Pillow) sobre paginas-imagen, lang spa+eng
Busqueda	Hibrida: similitud coseno + boost lexico por palabras clave
Conectores	Subida manual - Google Drive (GIS + Picker) - OneDrive (MSAL + Graph)
Modelos (IA)	NVIDIA NIM sobre HPE PCAI - Qwen3-Embedding-0.6B + Qwen3-30B
Generacion PDF	reportlab (plantilla de cotizacion / este documento)

Flujos principales

1. Ingesta e indexado

Subida manual o conectores (Google Drive / OneDrive) -> guardado en MinIO -> encolado en Redis/ARQ -> el worker extrae texto (PDF/DOCX/TXT/MD), aplica OCR (Tesseract) a las paginas que son imagen (tablas o propuestas escaneadas), hace chunking, embebe con NVIDIA NIM y hace upsert en Qdrant. Estados: pending -> processing -> indexed/failed.

2. Chat RAG con citas

La pregunta se embebe y se recuperan los fragmentos mas relevantes en Qdrant (filtrado por tenant y opcionalmente por documentos) con busqueda hibrida: similitud semantica mas un re-ranking lexico por palabras clave que rescata datos de tablas/OCR. Se arma el contexto y el LLM responde por streaming (SSE) citando las fuentes [n].

3. Cotizacion guiada por precedente

El usuario describe la cotizacion; el sistema rankea por documento las cotizaciones mas parecidas y pide confirmacion; con el precedente elegido (documento completo) el LLM genera el borrador reutilizando items y precios. El borrador es editable (cliente, items, impuestos con IVA 16% automatico, condiciones) y se exporta a PDF con plantilla generica.

Decisiones de arquitectura

- Qdrant en HPE PCAI (compartido, desplegado con apiKey:false); en desarrollo se uso un contenedor local y luego se apunto a PCAI sin migracion.
- OCR selectivo: solo se OCR-ean paginas con poco texto e imagenes, sin penalizar el resto del documento.
- Busqueda hibrida (semantica + lexica) para no perder datos en tablas/escaneos que la similitud pura deja fuera del top-k.
- Conectores cloud con patron cliente-amigable: tokens efimeros en el navegador (Google Identity Services / MSAL), sin almacenar refresh tokens.
- Single-tenant hoy, multi-tenant sin migracion: todo modelo y cada punto Qdrant llevan tenant_id.
- Subida manual primero; conectores externos via la interfaz Connector.
- Cotizaciones guiadas por precedente y editables tras la generacion, en vez de partir de cero.
- VERIFY_SSL=false hacia PCAI por certificados self-signed; credenciales por variables de entorno.