


Resumen

AIDOC es una plataforma de analisis documental conversacional (RAG). El usuario sube una biblioteca de documentos que se indexan en una base vectorial; luego puede chatear sobre ellos con respuestas citadas y generar cotizaciones guiadas por cotizaciones existentes. Aplicacion standalone (no fork de Onyx) que toma sus patrones. Single-tenant hoy, disenada para multi-tenant sin migracion.

Diagrama de componentes



Stack tecnologico

Capa	Tecnologia
Frontend	React 18 + Vite + TypeScript + TailwindCSS (SPA, SSE para streaming)
Backend / API	Python 3.11 + FastAPI (async), SQLAlchemy 2 + Alembic

Base de datos	PostgreSQL (metadata: documentos, chats, cotizaciones, organizacion)
Vector store	Qdrant (embeddings filtrados por tenant_id en el payload)
Almacenamiento	MinIO / S3 (archivos originales)
Cola / worker	Redis + ARQ (indexado asincrono en segundo plano)
Modelos (IA)	NVIDIA NIM sobre HPE PCAI - Qwen3-Embedding-0.6B + Qwen3-30B
Generacion PDF	reportlab (plantilla de cotizacion / este documento)

Flujos principales

1. Ingesta e indexado

Subida manual -> guardado en MinIO -> encolado en Redis/ARQ -> el worker extrae texto (PDF/DOCX/TXT), hace chunking, embebe con NVIDIA NIM y hace upsert en Qdrant. Estados: pending -> processing -> indexed/failed.

2. Chat RAG con citas

La pregunta se embebe y se buscan los fragmentos mas relevantes en Qdrant (filtrado por tenant y opcionalmente por documentos). Se arma el contexto y el LLM responde por streaming (SSE) citando las fuentes [n].

3. Cotizacion guiada por precedente

El usuario describe la cotizacion; el sistema rankea por documento las cotizaciones mas parecidas y pide confirmacion; con el precedente elegido (documento completo) el LLM genera el borrador reutilizando items y precios. Se exporta a PDF con plantilla generica.

Decisiones de arquitectura

- Qdrant en vez de Vespa: mas liviano y ya desplegado en PCAI.
- Single-tenant hoy, multi-tenant sin migracion: todo modelo y cada punto Qdrant llevan tenant_id.
- Subida manual primero; conectores externos (Drive/S3) como fase posterior via interfaz Connector.
- Cotizaciones guiadas por precedente: aprovechan la biblioteca como plantillas, en vez de partir de cero.
- VERIFY_SSL=false hacia PCAI por certificados self-signed; credenciales por variables de entorno.